

Simulação de Filas

Objetivo

Simular o comportamento de uma fila M/M/1 sob diferentes níveis de carga, coletar métricas de tempo de espera, tamanho da fila e utilização do servidor, e observar como o sistema se comporta quando se aproxima da saturação.

Contexto: Teoria das Filas

A teoria das filas é um ramo da matemática aplicada que modela sistemas onde chegadas e atendimentos ocorrem de forma aleatória. É amplamente usada em avaliação de desempenho de sistemas computacionais, redes e servidores.

O modelo M/M/1

O modelo M/M/1 é o mais simples e fundamental da teoria das filas:

- Primeiro M — chegadas seguem distribuição de Poisson (intervalos aleatórios com média constante)
- Segundo M — tempos de serviço seguem distribuição exponencial (aleatórios com média constante)
- 1 — um único servidor atendendo os clientes

Parâmetros fundamentais

- λ (lambda) — taxa de chegada: quantos clientes chegam por segundo em média
- μ (mu) — taxa de serviço: quantos clientes o servidor consegue atender por segundo
- ρ (rho) — utilização do servidor: $\rho = \lambda/\mu$

A regra mais importante

Quando $\rho < 1$, o sistema é estável — o servidor consegue dar conta das chegadas. Quando $\rho \rightarrow 1$, o sistema começa a saturar: a fila cresce indefinidamente e o tempo de espera explode. Este é o comportamento que você vai observar neste laboratório.

Pré-requisitos

- Docker e Docker Compose instalados
- Conhecimento básico de terminal Linux

- Noções de probabilidade e distribuições (desejável)

Como iniciar o laboratório

Abra um terminal nesta pasta e execute:

```
docker compose up -d
docker compose exec avd-lab-03 bash --login
```

Exercícios

Exercício 1 — Explorar o código do simulador

Antes de rodar a simulação, leia o código para entender o que está sendo simulado:

```
cat simulador.py
```

Identifique no código:

- O valor de `taxa_servico` — quantos clientes o servidor atende por segundo
- Os 4 cenários simulados e suas taxas de chegada
- O que cada métrica coletada representa

Por que simulação? Em sistemas reais, testar o comportamento próximo à saturação pode derrubar o serviço. A simulação permite estudar esses cenários com segurança, em qualquer escala de tempo.

Exercício 2 — Rodar a simulação

Execute o simulador:

```
./rodar_simulacao.sh
```

Os 4 cenários simulados são:

Cenário	Taxa chegada (λ)	Utilização (ρ)
Carga Leve	3 clientes/s	30%
Carga Média	5 clientes/s	50%
Carga Alta	7 clientes/s	70%
Carga Crítica	9 clientes/s	90%

O servidor atende 10 clientes/s em todos os cenários. Observe como as métricas mudam conforme a utilização aumenta.

Exercício 3 — Verificar o CSV gerado

```
cat resultados/simulacao_fila.csv
```

O formato é:

```
cenario,taxa_chegada,utilizacao_pct,espera_media_ms,tempo_sistema_ms,tamanho_fila_medio
Carga Leve (ρ=0.3),3,30.0,...
Carga Media (ρ=0.5),5,50.0,...
Carga Alta (ρ=0.7),7,70.0,...
Carga Critica (ρ=0.9),9,90.0,...
```

Copie toda a saída — você vai usar no Exercício 5.

Exercício 4 — Calcular os valores teóricos e comparar

A fila M/M/1 tem fórmulas fechadas que permitem calcular os valores esperados teoricamente. Compare os resultados da simulação com a teoria:

Fórmulas M/M/1:

- Utilização: $\rho = \lambda/\mu$
- Tempo médio de espera na fila: $Wq = \rho / (\mu - \lambda)$
- Tempo médio no sistema: $W = 1 / (\mu - \lambda)$
- Tamanho médio da fila: $Lq = \rho^2 / (1 - \rho)$

Para o cenário de Carga Alta ($\lambda=7$, $\mu=10$):

```
ρ = 7/10 = 0.7
Wq = 0.7 / (10 - 7) = 0.233s = 233ms
W = 1 / (10 - 7) = 0.333s = 333ms
Lq = 0.49 / 0.3 = 1.63 clientes
```

Compare esses valores com o que o simulador gerou. A diferença existe porque a simulação usa números aleatórios — com mais clientes simulados, os valores convergem para a teoria.

Exercício 5 — Visualizar no Datawrapper

Passo 1 — Acesse datawrapper.de e clique em Start creating.

Passo 2 — Clique em Copy & paste data table e cole o CSV completo.

Passo 3 — Clique em Proceed até chegar em Visualize.

Passo 4 — Escolha Column Chart.

Passo 5 — Na aba Refine → Select column, explore cada métrica:

- `espera_media_ms` — tempo médio de espera na fila

- tempo_sistema_ms — tempo total no sistema
- tamanho_fila_medio — quantos clientes aguardam em média

O que observar:

- Como a espera média muda entre $p=0.3$ e $p=0.9$?
- O crescimento é linear ou exponencial?
- O que acontece com o tamanho da fila quando p se aproxima de 1?

Exercício 6 — Análise dos resultados

Com base nos gráficos e nos valores teóricos, responda:

1. A espera média cresce de forma linear com a utilização? O que isso implica para o projeto de sistemas?
2. Qual a diferença entre $p=0.7$ e $p=0.9$ em termos de tempo de espera? O resultado surpreende?
3. Por que sistemas reais nunca devem operar com p próximo de 1?
4. Se o servidor fosse duas vezes mais rápido ($\mu=20$), qual seria o impacto na espera para o cenário de carga crítica?
5. Como esse modelo se relaciona com o que você observou no Lab 02 (Apache Bench)?

Conclusão: A teoria das filas mostra que a relação entre utilização e tempo de espera é altamente não-linear. Um sistema com 70% de utilização pode ser razoável, mas com 90% a espera pode ser 3 a 10 vezes maior. Por isso, sistemas em produção geralmente são dimensionados para operar entre 50% e 70% de utilização — deixando margem para picos de carga.

Como encerrar o laboratório

```
exit  
docker compose down
```

Os resultados ficam salvos na pasta resultados/ mesmo após encerrar o container.